



**Tecnológico  
de Monterrey**

**Uso de framework o biblioteca de aprendizaje máquina para la implementación de  
una solución**

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Alejandro Vázquez de la Cruz

09 de septiembre 2026

# Clustering de Breast Cancer Wisconsin con K-means + PCA

## Dataset

Se utilizó el dataset Breast Cancer Wisconsin (569 casos, 30 features numéricas, integrado en scikit-learn mediante `sklearn.datasets.load_breast_cancer`). La variable objetivo indica si el tumor es maligno o benigno.

K-means es un algoritmo no supervisado: durante el entrenamiento nunca ve esta etiqueta, solo agrupa los casos por cercanía en el espacio de features. El dataset se eligió específicamente porque sí tiene etiquetas reales, no para entrenar, sino para poder validar después qué tan bien los clusters encontrados coinciden con las clases verdaderas (algo que un dataset puramente exploratorio no permitiría).

| Clase     | Casos | Proporción |
|-----------|-------|------------|
| Benign    | 357   | 62.7%      |
| Malignant | 212   | 37.3%      |


División train/test: 80% entrenamiento (455 filas) / 20% prueba (114 filas), estratificada por la clase real.

## Metodología (Framework scikit-learn)

El pipeline utilizado es:

- `StandardScaler`: normaliza las 30 features antes de aplicar PCA y K-means, ya que ambos se basan en distancia, es necesario que las variables estén en un rango similar
- `PCA(n_components=2)`: reduce las 30 features a 2 componentes principales, que en conjunto explican 63.4% de la varianza. Se eligieron 2 componentes deliberadamente por motivos de visualización, no porque maximicen la varianza explicada (se necesitarían 7 componentes para llegar al 90%).
- `KMeans(n_clusters=2, n_init=10, random_state=42)`: `n_init=10` corre el algoritmo 10 veces con distintos centroides iniciales y conserva el resultado con menor inercia.


El número de clusters ( $k=2$ ) se fijó igual al número de clases reales, ya que el objetivo es comparar contra ellas. Como evidencia de que esa elección también es razonable sin conocer las etiquetas, se aplicó el método del codo sobre los datos reducidos por PCA:



La caída de inercia más pronunciada ocurre entre  $k=1$  y  $k=2$ , lo que sugiere que 2 es un número de clusters razonable incluso sin conocer las clases reales.

## Visualización: clases reales vs. clusters encontrados


Ambos paneles usan los mismos ejes (las 2 componentes principales) y la misma paleta de color, para poder comparar directamente qué tan bien coincide la agrupación de K-means con las clases reales:



Visualmente los dos paneles son casi idénticos; los pocos puntos que difieren de color se ubican en la zona donde ambos clusters se traslapan

## Resultados sobre el conjunto de prueba

Matriz de confusión (114 casos de prueba):



| Métrica   | Entrenamiento | Prueba | Fórmula                                                               |
|-----------|---------------|--------|-----------------------------------------------------------------------|
| Accuracy  | 90.1%         | 93.0%  | $(VP+VN) / \text{total}$                                              |
| Precision | 89.5%         | 93.2%  | $VP / (VP+FP)$                                                        |
| Recall    | 95.4%         | 95.8%  | $VP / (VP+FN)$                                                        |
| F1-score  | 92.4%         | 94.5%  | $2 \cdot (\text{Prec} \cdot \text{Rec}) / (\text{Prec} + \text{Rec})$ |

Justificación de las métricas: en un contexto médico, un falso negativo (predecir benigno cuando en realidad es maligno) es más costoso que un falso positivo, por lo que el recall sobre la clase "malignant" es la métrica más crítica a vigilar. El recall obtenido (95.8% en prueba) indica que el agrupamiento deja escapar muy pocos casos malignos. La precision (93.2%) y el F1 (94.5%) confirman que el resultado no se logra a costa de generar demasiados falsos positivos.

## Análisis y conclusión

K-means, sin recibir nunca la etiqueta real durante el entrenamiento, logró recuperar una separación que coincide en 93.0% de los casos de prueba con el diagnóstico real, usando únicamente 2 componentes principales que resumen el 63.4% de la información original. El desempeño en entrenamiento (90.1% accuracy) y en prueba (93.0%) es consistente entre sí, lo que indica que el agrupamiento encontrado refleja una estructura real presente en los datos y no un ajuste específico a la muestra de entrenamiento.

Los pocos errores (5 falsos negativos y 3 falsos positivos, de 114 casos de prueba) se concentran, según la visualización de PCA, en la región donde los clústers de ambas clases se traslapan, es decir, en casos donde las propias features del tumor son

ambiguas incluso antes de aplicar cualquier algoritmo, no en una falla evidente del método.

Es importante no perder de vista la limitación conceptual de este ejercicio: en un escenario real de clustering no se cuenta con etiquetas para validar. Aquí se usaron únicamente después de entrenar, para medir qué tan bien la agrupación no supervisada se parece a una clasificación conocida, el método del codo confirmó que  $k=2$  también sería una elección razonable sin conocer las clases reales, pero en un dataset sin ground truth no sería posible calcular accuracy, precision, recall ni matriz de confusión; solo métricas internas como el silhouette score.